

最优化方法：基础知识习题解答

162350107 冉茂印

March 14, 2025

Code Repository: https://github.com/myRan-cyber/OMW/tree/main/first_hw

More Details <https://zhuanlan.zhihu.com/p/30307011306>

Problem 1. 设 $f(x) = \|Ax - \mathbf{y}\|^2$, 其中 A 为列满秩矩阵。

- 使用逐分量计算梯度方式计算 $\frac{\partial f}{\partial x_k}$;
- 使用整体的方法计算梯度 $\frac{\partial f}{\partial \mathbf{x}}$ 。

Ans.

Part (a): 逐分量梯度计算 展开平方范数:

$$f(\mathbf{x}) = \sum_{i=1}^m \left(\sum_{j=1}^n A_{ij} x_j - y_i \right)^2.$$

对 x_k 求偏导:

$$\frac{\partial f}{\partial x_k} = 2 \sum_{i=1}^m A_{ik} \left(\sum_{j=1}^n A_{ij} x_j - y_i \right).$$

$$\frac{\partial f}{\partial x_k} = 2 [A^\top (A\mathbf{x} - \mathbf{y})]_k.$$

$$\boxed{\nabla f(\mathbf{x}) = 2A^\top (A\mathbf{x} - \mathbf{y})}.$$

Part (b): 整体梯度计算 将 $f(\mathbf{x})$ 展开平方范数:

$$f(\mathbf{x}) = (A\mathbf{x} - \mathbf{y})^\top (A\mathbf{x} - \mathbf{y}) = \mathbf{x}^\top A^\top A\mathbf{x} - 2\mathbf{y}^\top A\mathbf{x} + \mathbf{y}^\top \mathbf{y}.$$

对 \mathbf{x} 求梯度:

$$\frac{\partial}{\partial \mathbf{x}} (\mathbf{x}^\top A^\top A\mathbf{x}) = 2A^\top A\mathbf{x},$$

$$\frac{\partial}{\partial \mathbf{x}} (-2\mathbf{y}^\top A\mathbf{x}) = -2A^\top \mathbf{y},$$

$$\frac{\partial}{\partial \mathbf{x}} (\mathbf{y}^\top \mathbf{y}) = \mathbf{0}.$$

得:

$$\boxed{\nabla f(\mathbf{x}) = 2A^\top (A\mathbf{x} - \mathbf{y})}.$$

Problem 2. 设 $f(\mathbf{x}) = \text{tr}(\sigma^2 I + \mathbf{x}\mathbf{x}^\top)$, 其中 $\sigma > 0$, I 为 $n \times n$ 单位矩阵, $\mathbf{x} \in \mathbb{R}^n$.

- 使用逐分量计算梯度方式计算 $\frac{\partial f}{\partial x_k}$;
- 使用整体的方法计算梯度 $\frac{\partial f}{\partial \mathbf{x}}$ 。

Ans.

Part (a): 逐分量梯度计算

$$f(\mathbf{x}) = \text{tr}(\sigma^2 I) + \text{tr}(\mathbf{x}\mathbf{x}^\top).$$

$$f(\mathbf{x}) = n\sigma^2 + \sum_{i=1}^n x_i^2.$$

对 x_k 求偏导:

$$\frac{\partial f}{\partial x_k} = \frac{\partial}{\partial x_k} \left(n\sigma^2 + \sum_{i=1}^n x_i^2 \right) = 2x_k.$$

得:

$$\boxed{\nabla f(\mathbf{x}) = (2x_1, 2x_2, \dots, 2x_n)^\top}.$$

Part (b): 整体梯度计算 对 $f(\mathbf{x}) = \text{tr}(\sigma^2 I + \mathbf{x}\mathbf{x}^\top)$ 求微分:

$$df = \text{tr}(d(\mathbf{x}\mathbf{x}^\top)) = \text{tr}(d\mathbf{x} \cdot \mathbf{x}^\top + \mathbf{x} \cdot d\mathbf{x}^\top).$$

$$df = 2\text{tr}(\mathbf{x}^\top d\mathbf{x}) = 2\mathbf{x}^\top d\mathbf{x}.$$

$$\boxed{\nabla f(\mathbf{x}) = 2\mathbf{x}}.$$

Problem 3. 考虑二次型 $f(x) = x^\top Qx$, 其中 $x \in \mathbb{R}^n$, $Q \in \mathbb{R}^{n \times n}$, 且 Q 的特征值分解为

$$Q = U\Lambda U^\top,$$

其中 U 为正交矩阵, 特征值为 $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n \geq 0$.

a. 证明:

$$\lambda_1 = \max_{\|x\|=1} x^\top Qx = \max_{x \neq 0} \frac{x^\top Qx}{x^\top x}.$$

b. 证明: 对任意 $x \in \mathbb{R}^n$, $x \neq 0$, 有

$$\lambda_n \|x\|^2 \leq x^\top Qx \leq \lambda_1 \|x\|^2.$$

Ans.

Part (a) 令 $y = U^\top x$, 则 $x = Uy$,

$$x^\top Qx = y^\top U^\top Q U y = y^\top \Lambda y = \sum_{i=1}^n \lambda_i y_i^2.$$

当 $\|x\| = 1$ 时, $\|y\| = 1$, 即 $\sum_{i=1}^n y_i^2 = 1$

$$x^\top Qx = \sum_{i=1}^n \lambda_i y_i^2 \leq \lambda_1 \sum_{i=1}^n y_i^2 = \lambda_1.$$

当 $y_1 = 1$, 其余 $y_i = 0$ 时, 等号成立, 故:

$$\max_{\|x\|=1} x^\top Qx = \lambda_1.$$

对任意 $x \neq 0$,

$$\frac{x^\top Qx}{x^\top x} = \frac{\sum_{i=1}^n \lambda_i y_i^2}{\sum_{i=1}^n y_i^2} \leq \lambda_1.$$

当 $y_1 \neq 0$, 其余 $y_i = 0$ 时, 等号成立, 故:

$$\max_{x \neq 0} \frac{x^\top Qx}{x^\top x} = \lambda_1.$$

Part (b) 由 $\lambda_n \leq \lambda_i \leq \lambda_1$, 对任意 $y \in \mathbb{R}^n$, 有:

$$\lambda_n \sum_{i=1}^n y_i^2 \leq \sum_{i=1}^n \lambda_i y_i^2 \leq \lambda_1 \sum_{i=1}^n y_i^2.$$

由于 $\sum_{i=1}^n y_i^2 = \|x\|^2$, 代入得:

$$\lambda_n \|x\|^2 \leq x^\top Qx \leq \lambda_1 \|x\|^2.$$

当 x 分别为 Q 的最小和最大特征值对应的特征向量时, 等号成立。

Problem 4. 给定二次型 $f(x) = 3x_1^2 + 4x_2^2 + 3x_3^2 + 2x_1x_3$, 完成以下问题:

- 将此二次型写成矩阵-向量形式, 并求其标准型;
- 证明: $\min_{x \neq 0} \frac{f(x)}{\|x\|^2} = 2$;
- 证明集合 $\{x \in \mathbb{R}^3 \mid f(x) = 1\}$ 是一个椭球, 并计算其长轴与短轴之比;
- 计算 $\nabla^2 f(x)$ 的条件数。

Ans.

Part (a): 将二次型写成 $f(x) = x^\top Qx$, 其中 Q 为:

$$Q = \begin{pmatrix} 3 & 0 & 1 \\ 0 & 4 & 0 \\ 1 & 0 & 3 \end{pmatrix}.$$

对 Q 特征分解, $\det(Q - \lambda I) = 0$, 得:

$$\lambda_1 = 4 \text{ (二重根)}, \quad \lambda_2 = 2.$$

通过 $x = Uy$, 二次型化为标准型:

$$f(x) = 4y_1^2 + 4y_2^2 + 2y_3^2.$$

Part (b): 由瑞利商性质, 最小值等于 Q 的最小特征值 (上一题已证):

$$\min_{x \neq 0} \frac{x^\top Qx}{x^\top x} = \lambda_{\min}(Q) = 2.$$

当 x 为 Q 对应特征值 2 的特征向量时, 等号成立。

Part (c): $f(x) = 1$ 对应标准型:

$$4y_1^2 + 4y_2^2 + 2y_3^2 = 1 \implies \frac{y_1^2}{(1/2)^2} + \frac{y_2^2}{(1/2)^2} + \frac{y_3^2}{(1/\sqrt{2})^2} = 1.$$

椭球的半轴长度为 $a = 1/2, b = 1/2, c = 1/\sqrt{2}$ 。长轴为 c , 短轴为 a , 其比为:

$$\frac{c}{a} = \frac{1/\sqrt{2}}{1/2} = \sqrt{2}.$$

Part (d): Hessian 矩阵为 $\nabla^2 f(x) = 2Q$, 其特征值为 8, 8, 4。条件数为最大特征值与最小特征值之比:

$$\kappa(\nabla^2 f(x)) = \frac{8}{4} = 2.$$

Problem 5. 计算函数

$$f(x) = \log \sum_{i=1}^n \exp x_i$$

的梯度和 Hessian 矩阵, 并证明 Hessian 矩阵正定。

Ans.

对 x_j 求偏导数:

$$\frac{\partial f}{\partial x_j} = \frac{\exp x_j}{\sum_{i=1}^n \exp x_i}.$$

令 $S = \sum_{i=1}^n \exp x_i$, 则梯度向量为:

$$\nabla f(x) = \left(\frac{\exp x_1}{S}, \frac{\exp x_2}{S}, \dots, \frac{\exp x_n}{S} \right)^T.$$

对角元素 ($i = j$)

$$\frac{\partial^2 f}{\partial x_j^2} = \frac{\exp x_j (S - \exp x_j)}{S^2}.$$

非对角元素 ($i \neq j$)

$$\frac{\partial^2 f}{\partial x_i \partial x_j} = \frac{-\exp x_i \exp x_j}{S^2}.$$

因此, Hessian 矩阵为:

$$H = \begin{pmatrix} \frac{\exp x_1 (S - \exp x_1)}{S^2} & \frac{-\exp x_1 \exp x_2}{S^2} & \dots & \frac{-\exp x_1 \exp x_n}{S^2} \\ \frac{-\exp x_2 \exp x_1}{S^2} & \frac{\exp x_2 (S - \exp x_2)}{S^2} & \dots & \frac{-\exp x_2 \exp x_n}{S^2} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{-\exp x_n \exp x_1}{S^2} & \frac{-\exp x_n \exp x_2}{S^2} & \dots & \frac{\exp x_n (S - \exp x_n)}{S^2} \end{pmatrix}.$$

对任意非零向量 $z = (z_1, z_2, \dots, z_n)^T$, 计算二次型:

$$\begin{aligned} z^T H z &= \sum_{i=1}^n \frac{\exp x_i (S - \exp x_i)}{S^2} z_i^2 + \sum_{i \neq j} \frac{-\exp x_i \exp x_j}{S^2} z_i z_j. \\ &= \frac{1}{S^2} \left(S \sum_{i=1}^n \exp x_i z_i^2 - \sum_{i=1}^n (\exp x_i z_i)^2 - \sum_{i \neq j} \exp x_i \exp x_j z_i z_j \right). \\ &= \frac{1}{S^2} \left(S \sum_{i=1}^n \exp x_i z_i^2 - \left(\sum_{i=1}^n \exp x_i z_i \right)^2 \right). \end{aligned}$$

令 $p_i = \frac{\exp x_i}{S}$, 则:

$$z^T H z = \frac{1}{S} \left(\sum_{i=1}^n p_i z_i^2 - \left(\sum_{i=1}^n p_i z_i \right)^2 \right).$$

上式等价于概率分布 p_i 下 z 的方差, 故:

$$z^T H z \geq 0.$$

当且仅当 z 为常数向量时, 方差为零, 因此 H 是半正定矩阵。

Problem 6. 设 A 为对称矩阵, 计算下式的梯度:

$$\ell(\mathbf{x}) = \|A - \mathbf{x}\mathbf{x}^T\|^2$$

Ans.

$$\ell(\mathbf{x}) = \text{tr}((A - \mathbf{x}\mathbf{x}^T)^T(A - \mathbf{x}\mathbf{x}^T)).$$

展开后得到:

$$\ell(\mathbf{x}) = \text{tr}(A^T A) - 2\text{tr}(A\mathbf{x}\mathbf{x}^T) + \text{tr}(\mathbf{x}\mathbf{x}^T \mathbf{x}\mathbf{x}^T).$$

第一项 $\text{tr}(A^T A)$

$$d \text{tr}(A^T A) = 0.$$

第二项 $-2\text{tr}(A\mathbf{x}\mathbf{x}^T)$

$$d \text{tr}(A\mathbf{x}\mathbf{x}^T) = \text{tr}(A(d\mathbf{x})\mathbf{x}^T + A\mathbf{x}(d\mathbf{x}^T)).$$

$$d \text{tr}(A\mathbf{x}\mathbf{x}^T) = 2\text{tr}(A\mathbf{x}d\mathbf{x}^T).$$

$$d(-2\text{tr}(A\mathbf{x}\mathbf{x}^T)) = -4\text{tr}(A\mathbf{x}d\mathbf{x}^T).$$

第三项 $\text{tr}(\mathbf{x}\mathbf{x}^T \mathbf{x}\mathbf{x}^T)$

$$\text{tr}(\mathbf{x}\mathbf{x}^T \mathbf{x}\mathbf{x}^T) = (\mathbf{x}^T \mathbf{x})^2 = \|\mathbf{x}\|^4.$$

对 $\|\mathbf{x}\|^4$ 求微分:

$$d(\|\mathbf{x}\|^4) = 4\|\mathbf{x}\|^2 \mathbf{x}^T d\mathbf{x}.$$

$$d\ell = -4\text{tr}(A\mathbf{x}d\mathbf{x}^T) + 4\|\mathbf{x}\|^2 \mathbf{x}^T d\mathbf{x}.$$

$$d\ell = (-4A\mathbf{x} + 4\|\mathbf{x}\|^2 \mathbf{x})^T d\mathbf{x}.$$

$$\nabla \ell(\mathbf{x}) = -4A\mathbf{x} + 4\|\mathbf{x}\|^2 \mathbf{x}.$$

$$\nabla \ell(\mathbf{x}) = 4(\|\mathbf{x}\|^2 \mathbf{x} - A\mathbf{x}).$$

梯度向量为:

$$\boxed{\nabla \ell(\mathbf{x}) = 4(\|\mathbf{x}\|^2 \mathbf{x} - A\mathbf{x})}.$$

Problem 7. 设 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 为正定二次型 $f(x) = x^\top Qx$, 多变量正态分布为:

$$p(x|\mu, \Sigma) = \frac{1}{(2\pi)^{\frac{n}{2}} |\Sigma|^{\frac{1}{2}}} \exp\left(-\frac{1}{2}(x - \mu)^\top \Sigma^{-1}(x - \mu)\right),$$

计算积分:

$$J(\mu, \Sigma) = \int_{\mathbb{R}^n} f(x)p(x|\mu, \Sigma) dx.$$

Ans.

$J(\mu, \Sigma)$ 等价于二次型 $f(x)$ 在正态分布下的期望：

$$J(\mu, \Sigma) = \mathbb{E}_{x \sim \mathcal{N}(\mu, \Sigma)} [x^\top Q x] .$$

$$x^\top Q x = \text{tr}(x^\top Q x) = \text{tr}(Q x x^\top) .$$

$$\mathbb{E}[x^\top Q x] = \text{tr} (Q \cdot \mathbb{E}[x x^\top]) .$$

对于 $x \sim \mathcal{N}(\mu, \Sigma)$, 其二阶矩为：

$$\mathbb{E}[x x^\top] = \Sigma + \mu \mu^\top .$$

$$\mathbb{E}[x^\top Q x] = \text{tr} (Q(\Sigma + \mu \mu^\top)) .$$

$$\text{tr} (Q(\Sigma + \mu \mu^\top)) = \text{tr}(Q \Sigma) + \text{tr}(Q \mu \mu^\top) .$$

$$\text{tr}(Q \mu \mu^\top) = \text{tr}(\mu^\top Q \mu) = \mu^\top Q \mu .$$

$$\boxed{J(\mu, \Sigma) = \mu^\top Q \mu + \text{tr}(Q \Sigma)} .$$